CUCEI
CENTRO UNIVERSITARIO DE CIENCIAS EXACTAS E INGENIERÍAS

UNIVERSIDAD DE GUADALAJARA
PIENSA Y TRABAJA

Regresión Lineal y Regresión Logística

Aprendizaje Máquina

Actividad 4

Alumno: Quijas Contreras Victor Manuel

Código: 220429771

Carrera: ICOM

Departamento: Innovación Basada en la Información y el Conocimiento.

Profesor: Emilio Barajas González

Fecha: 26/10/2026

Índice

Índice 1
Tabla de ilustraciones 1
Introducción 2
Regresión Lineal 2
¿Qué información proporciona respecto a los datos de pasajeros del Titanic? 2
Regresión Lineal 3
Matriz de Confusión 3
Curva ROC y Área Bajo la Curva (AUC) 4
Resultados 5
Regresión Lineal 5
Graficas respecto a la variable entre variables 5
Conclusiones respecto a la variable 'Edad' 9
Conclusiones respecto a la variable 'Tarifa' 9
Conclusiones respecto a la variable de 'ascendencia y descendencia' 9
Conclusiones respecto a la variable 'Hermanos y conyugues' 10
Regresión Logística 11
Conclusión 13
Bibliografía 13

Tabla de ilustraciones

Ilustración 1. Histograma de las edades de los pasajeros del Titanic clasificado por género y clase de huésped. Además de la regresión lineal aplicada a las gráficas de dispersión con edad como variable principal. Fuentes: elaboración propia. 5
Ilustración 2. Histograma de la tarifa de los pasajeros del Titanic clasificado por género y clase de huésped. Además de la regresión lineal aplicada a las gráficas de dispersión con Taria como la variable principal. Fuentes: elaboración propia. 6
Ilustración 3. Histograma del parentesco ascendente y descendente de los pasajeros clasificado por género y clase de huésped. Además de la regresión lineal aplicada a las gráficas de dispersión. Fuentes: elaboración propia. 7
Ilustración 4. Histograma del parentesco lateral de los pasajeros clasificado por género y clase de huésped. Además de la regresión lineal aplicada a las gráficas de dispersión. Fuentes: elaboración propia. 8

Ilustración 5. Comparativa de dos matrices de confusión con un umbral distinto. Fuentes: elaboración propia. 11
Ilustración 6. Función sigmoide a los pasajeros de pruea. Y comparación entre humbrales. Fuentes: elaboración propia. 11
Ilustración 7. Curva ROC y AUC 12

Introducción

Regresión Lineal

La regresión lineal es un algoritmo de aprendizaje supervisado y modelado estadístico que busca establecer una relación funcional de carácter lineal entre una variable respuesta continua Y y una o más variables explicativas o predictoras $X_1, X_2, \dots, X_p$. Su ecuación general se expresa como:

$$Y = \beta_0 + \beta_1 X_1 + \beta_2 X_2 + \cdots + \beta_p X_p + \epsilon$$

Donde:

- β_0 es el intercepto
- β_i representa la magnitud y dirección del efecto de cada variable independiente
- ϵ es el término de error aleatorio.

Su objetivo es predecir un valor numérico continuo y analizar la influencia relativa de cada factor sobre la variable dependiente.

¿Qué información proporciona respecto a los datos de pasajeros del Titanic?

La regresión lineal resulta útil para predecir o explicar variables cuantitativas continuas de los pasajeros, tales como:

- **Tarifa del billete (*Fare*):** Analizar en qué medida la clase del pasaje (*Pclass*), el puerto de embarque (*Embarked*) o el tamaño de la familia a bordo influyeron en el costo económico pagado.
- **Estimación de la edad (*Age*):** Predecir la edad de los pasajeros que no registran este dato a partir de predictores como el título honorífico (Sr., Sra., Miss), la tarifa pagada y la clase.
- **Modelo de Probabilidad Lineal (MPL):** Servir como referente metodológico para ilustrar por qué la regresión lineal tradicional no es adecuada para clasificar la supervivencia (al generar probabilidades fuera del rango $[0,1]$ y violar el supuesto de homocedasticidad).

Regresión Lineal

La regresión logística es un modelo supervisado diseñado para abordar problemas de clasificación binaria, donde la variable respuesta Y adopta únicamente dos estados posibles ($Y \in \{0,1\}$), correspondiendo en este caso a sobrevivir (1) o no sobrevivir (0).

En lugar de estimar una recta continua sin límites, la regresión logística modela la probabilidad condicional $P(Y = 1|X)$ transformando la combinación lineal de las variables explicativas mediante la **función sigmoide** (o función logística):

$$P(Y = 1|X) = \sigma(z) = \frac{1}{1 + e^{-z}}$$

donde $z = \beta_0 + \beta_1 X_1 + \cdots + \beta_p X_p$.

- **Comportamiento de la función sigmoide:** Mapea cualquier número real $z \in (-\infty, +\infty)$ al intervalo acotado $(0,1)$. Si z asume valores positivos elevados, la probabilidad se aproxima a 1; si z es marcadamente negativo, se aproxima a 0. Esto otorga a las salidas una interpretación directa como la probabilidad de supervivencia del pasajero en función de variables como sexo, clase o edad.

Matriz de Confusión

La matriz de confusión es una tabla que permite evaluar la precisión de las predicciones del modelo comparando las clases reales frente a las predichas tras establecer un umbral de decisión (frecuentemente 0.5):

	Predicción: No Sobrevivió (0)	**Predicción: Sobrevivió (1)**
Real: No Sobrevivió (0)	Verdadero Negativo (TN)	Falso Positivo (FP)
Real: Sobrevivió (1)	Falso Negativo (FN)	Verdadero Positivo (TP)

A partir de esta estructura se calculan las métricas clave de evaluación:

- **Exactitud:** Porcentaje global de clasificaciones correctas: $\frac{TP+TN}{TP+TN+FP+FN}$
- **Sensibilidad:** Proporción de sobrevivientes reales identificados correctamente por el modelo: $\frac{TP}{TP+FN}$
- **Especificidad:** Proporción de no sobrevivientes reales identificados correctamente: $\frac{TN}{TN+FP}$
- **Precisión:** Proporción de casos predichos como sobrevivientes que realmente lo fueron: $\frac{TP}{TP+FP}$

Curva ROC y Área Bajo la Curva (AUC)

La Curva ROC es una representación gráfica que evalúa la capacidad discriminativa del modelo a través de todos los umbrales de decisión posibles (0 a 1). Se construye graficando:

- **Eje Y:** Tasa de Verdaderos Positivos (Sensibilidad).
- **Eje X:** Tasa de Falsos Positivos ($1 -$ Especificidad).

El Área Bajo la Curva (AUC-ROC) sintetiza la curva ROC en un único valor numérico comprendido entre 0.5 y 1.0:

- AUC $= 0.5$**:** Indica una capacidad de discriminación nula (equivalente a una predicción aleatoria).
- AUC $= 1.0$**:** Representa un clasificador perfecto sin errores de estimación.

En el contexto del Titanic, la curva ROC y el AUC cuantifican la solidez global de la regresión logística para distinguir correctamente entre pasajeros sobrevivientes y no sobrevivientes.

Resultados

Regresión Lineal

Graficas respecto a la variable entre variables

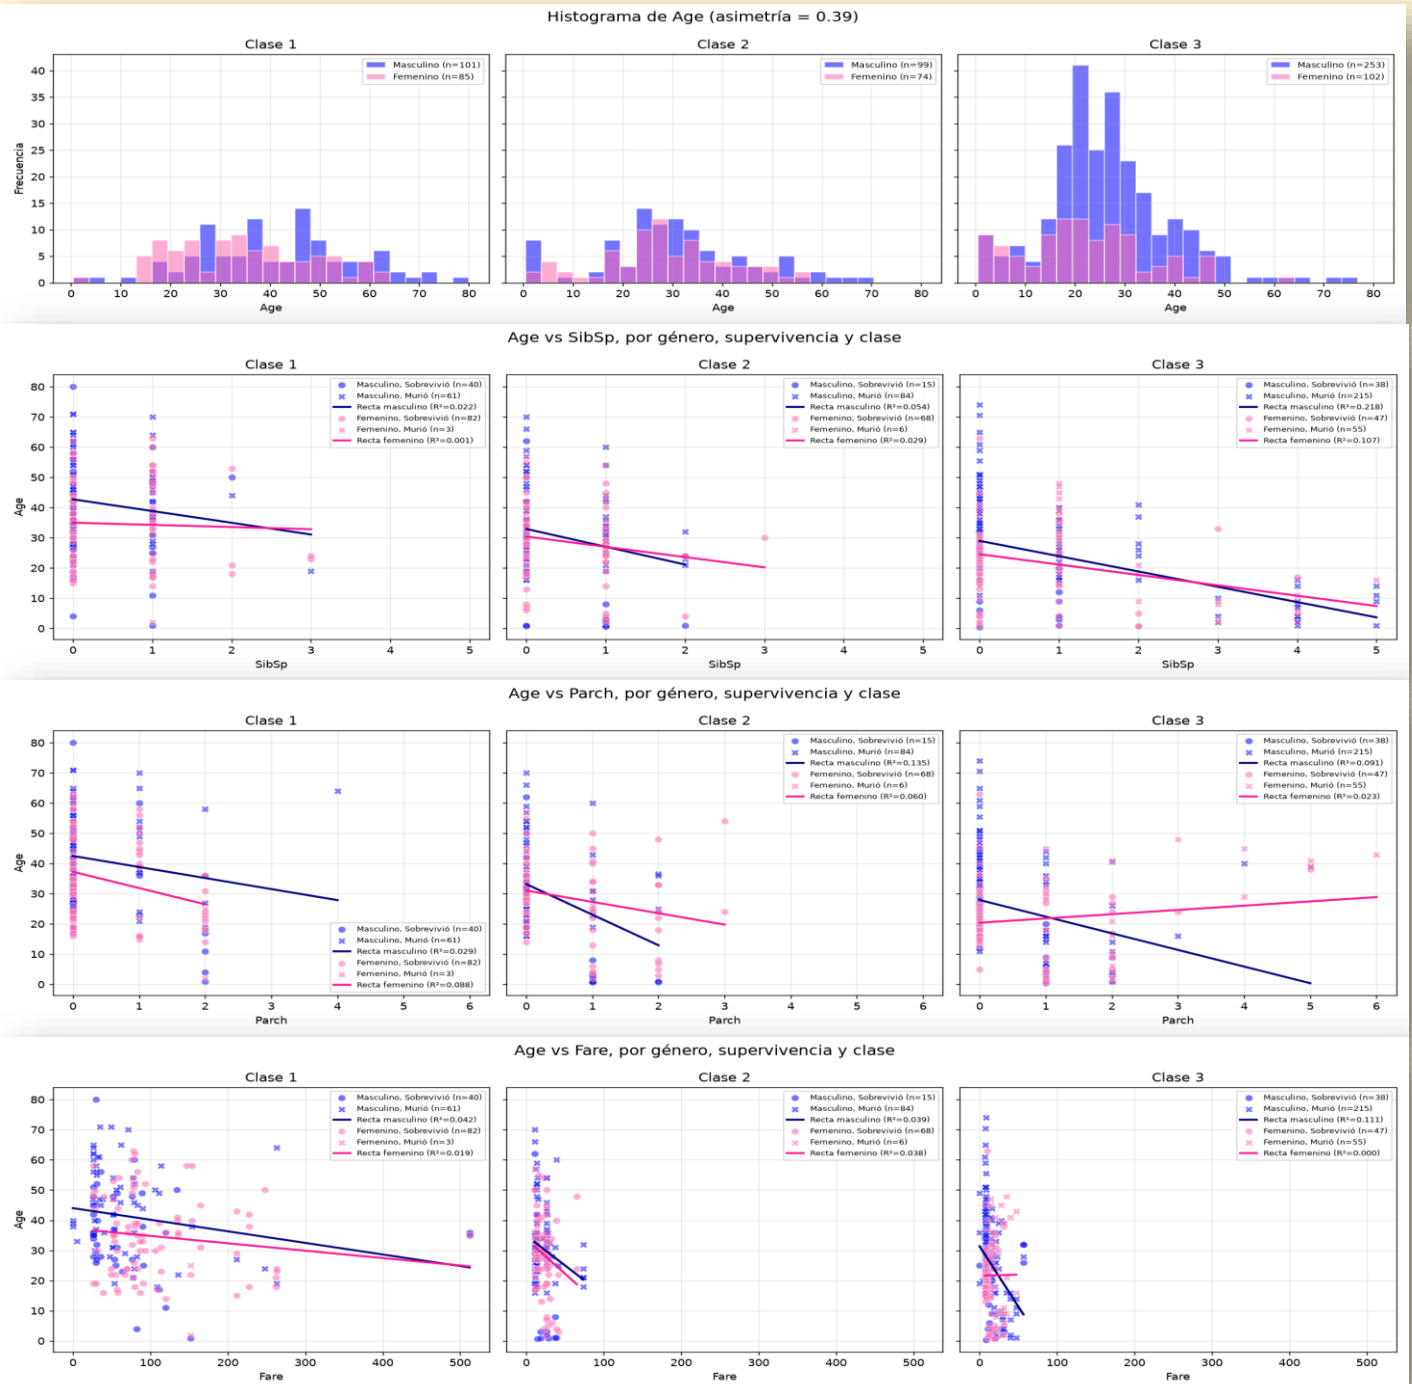


***Ilustración 1**. Histograma de las edades de los pasajeros del Titanic clasificado por género y clase de huésped. Además de la regresión lineal aplicada a las gráficas de dispersión con edad como variable principal. Fuentes: elaboración propia.*

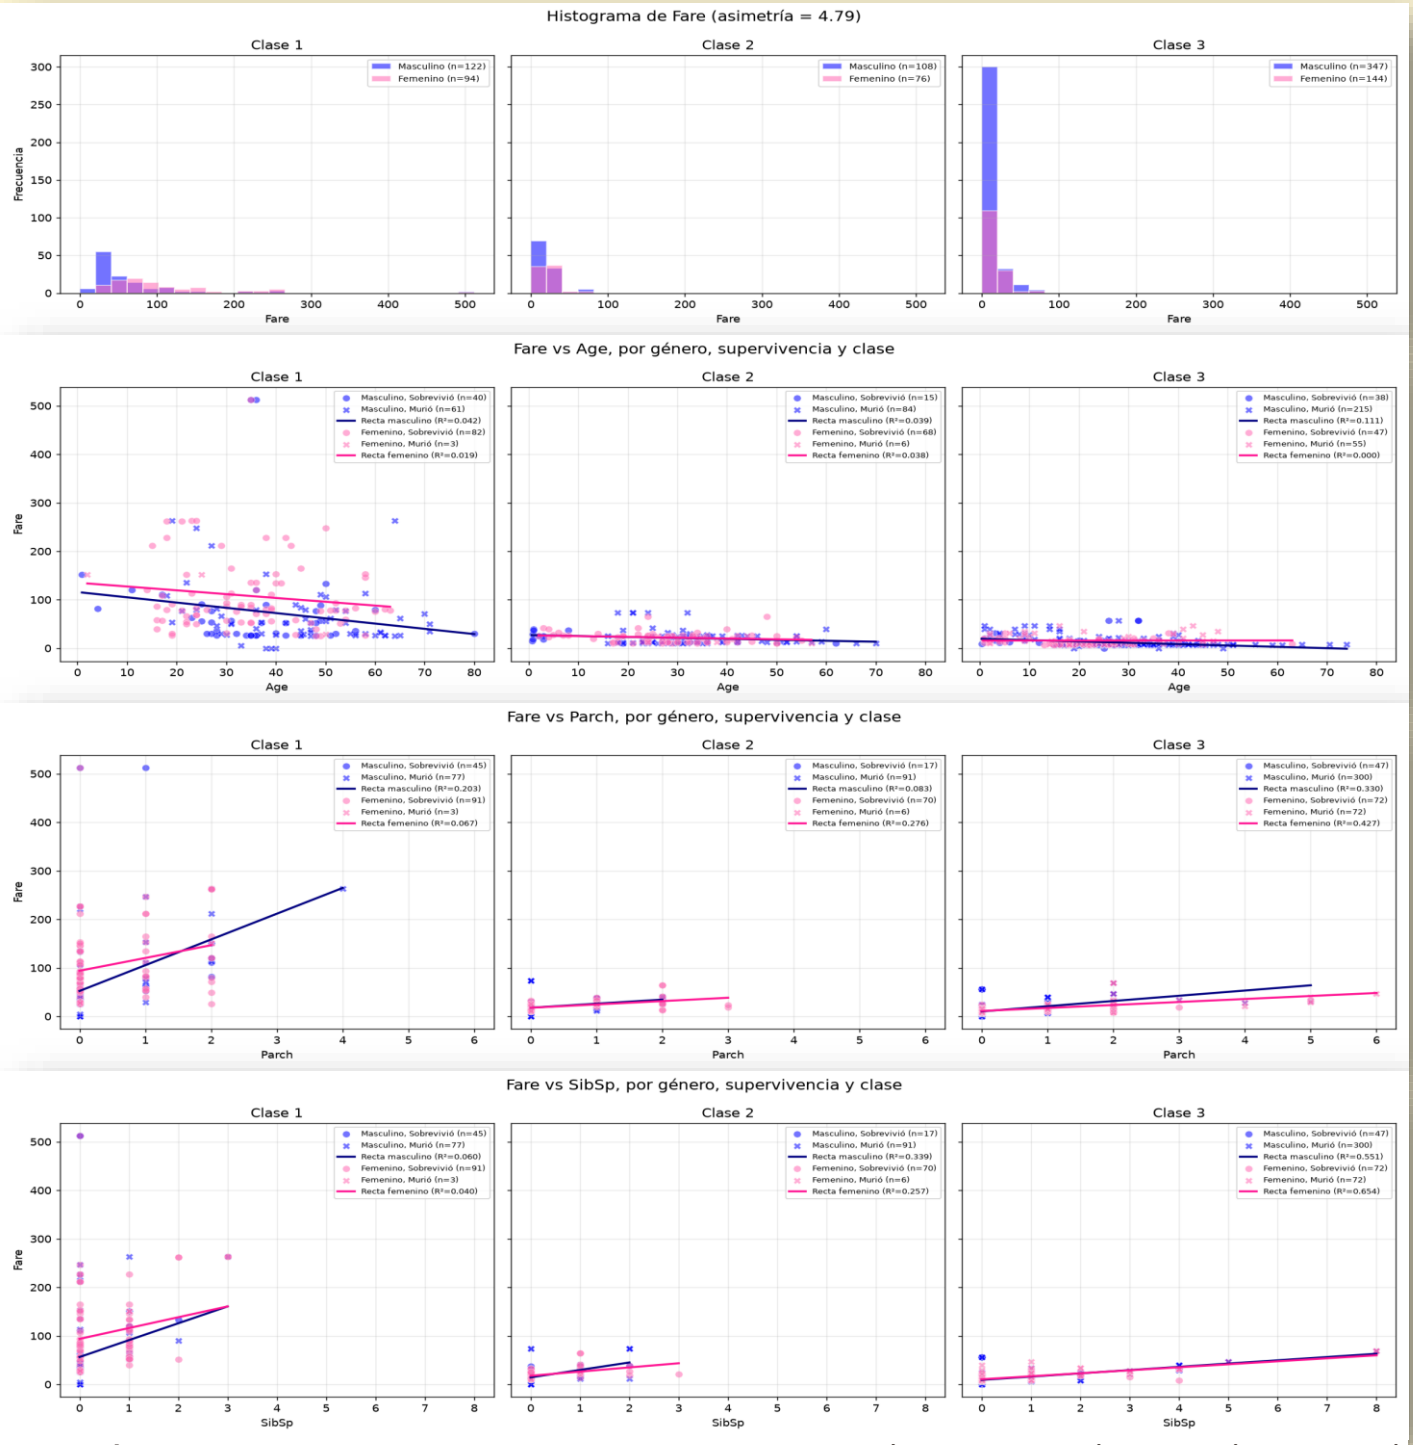


Ilustración 2. *Histograma de la tarifa de los pasajeros del Titanic clasificado por género y clase de huésped. Además de la regresión lineal aplicada a las gráficas de dispersión con Taria como la variable principal. Fuentes: elaboración propia.*

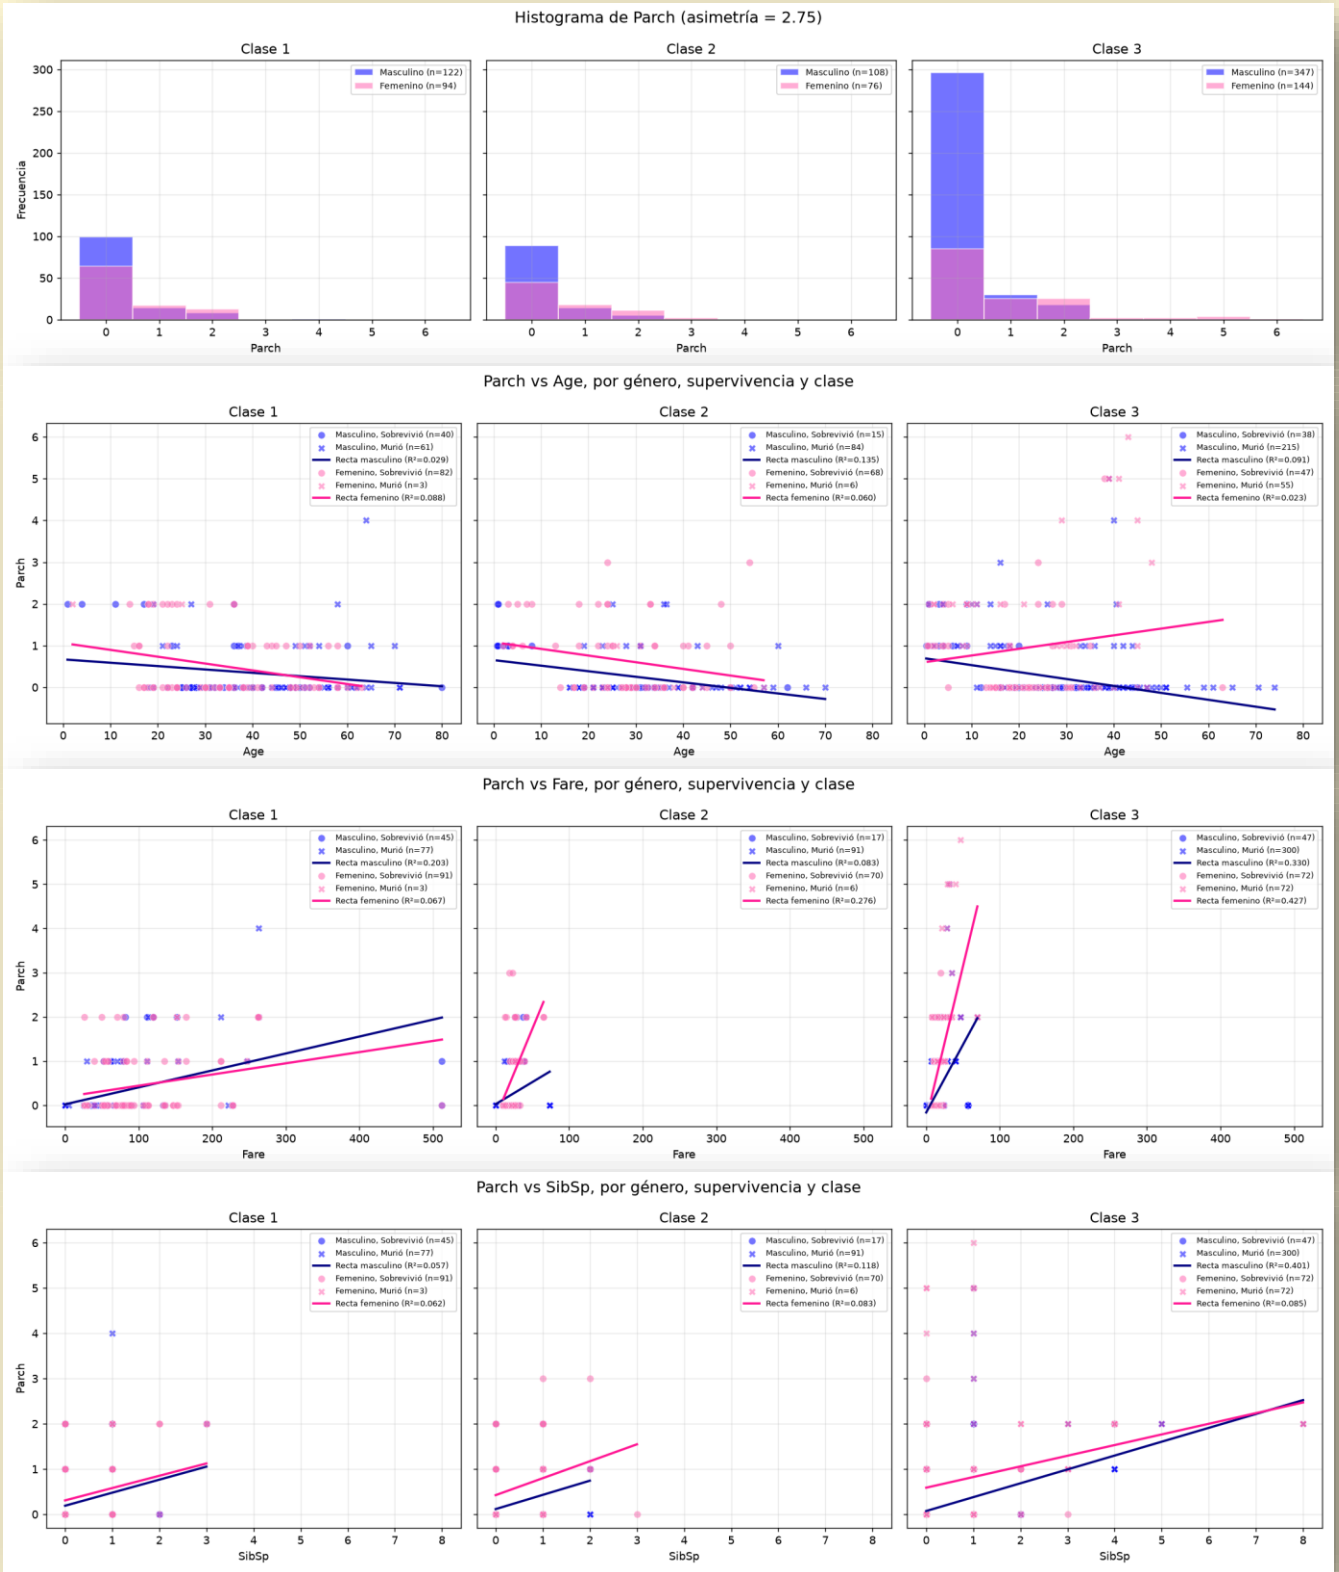


Ilustración 3. *Histograma del parentesco ascendente y descendente de los pasajeros clasificado por género y clase de huésped. Además de la regresión lineal aplicada a las gráficas de dispersión. Fuentes: elaboración propia.*

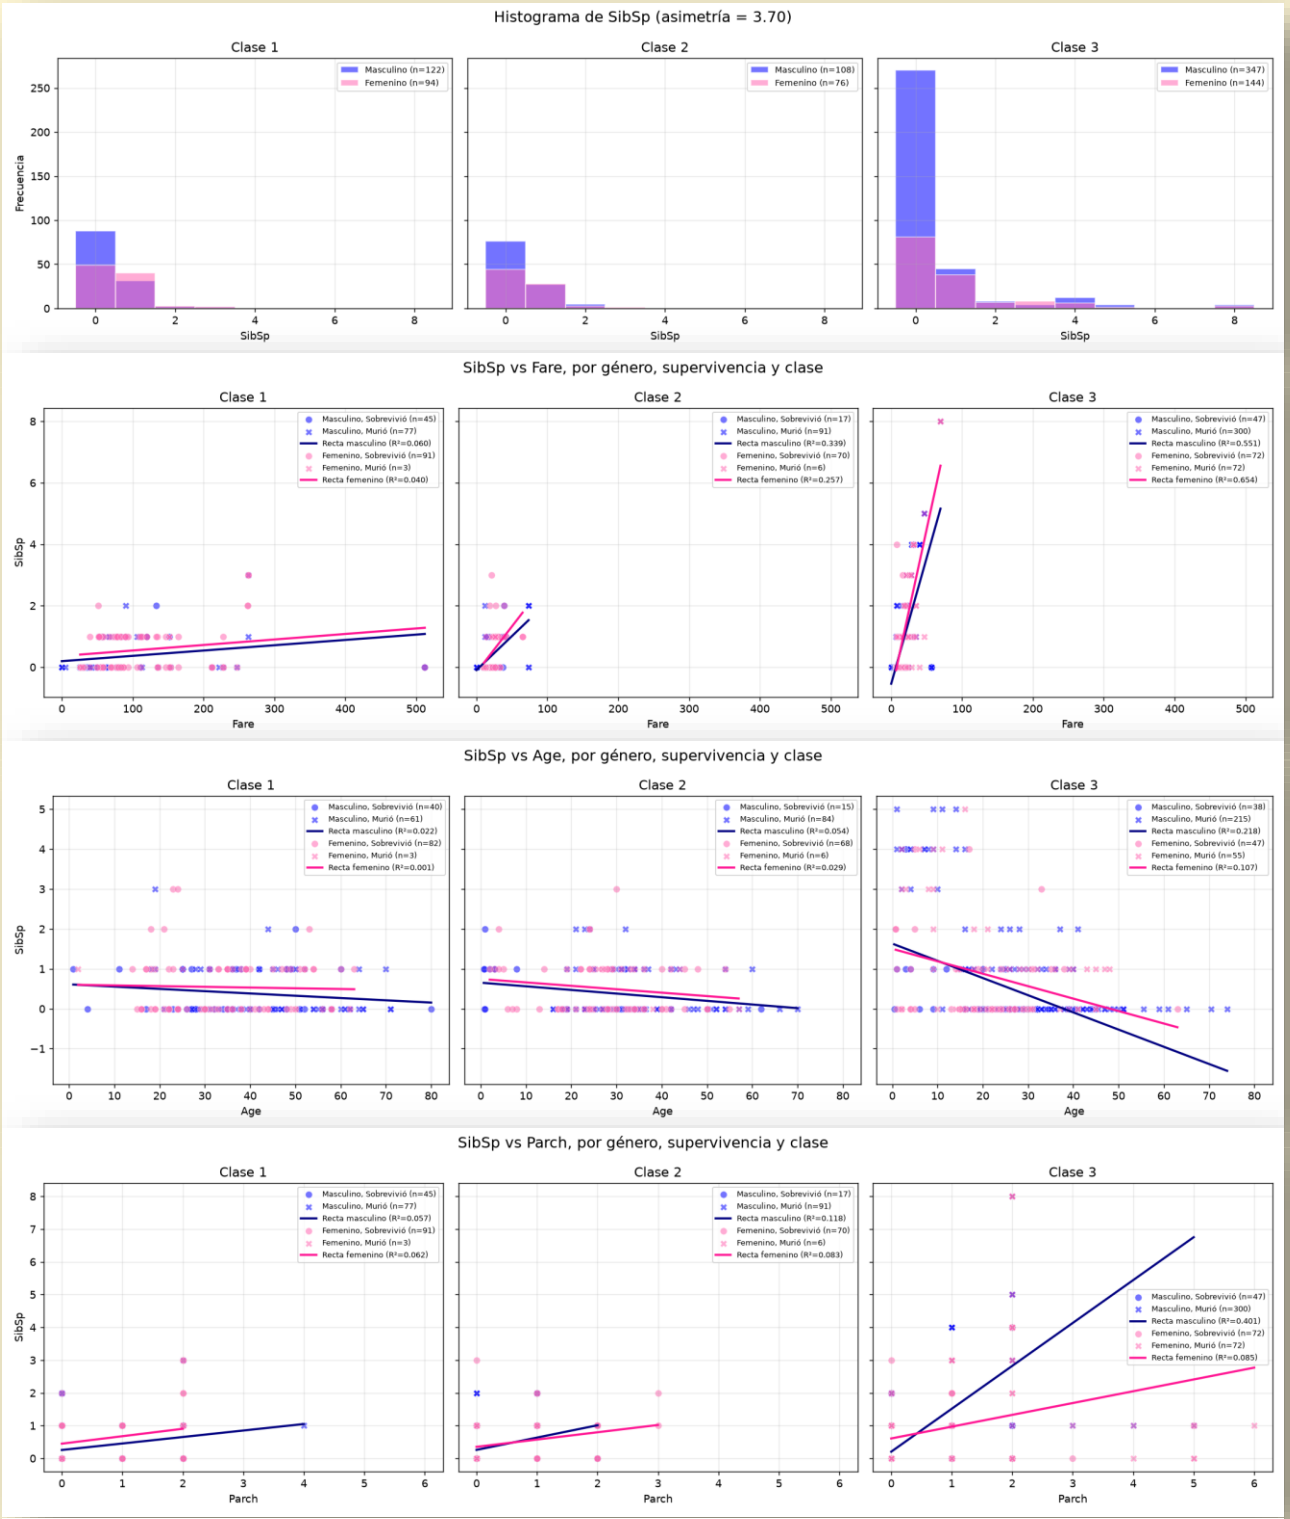


Ilustración 4. *Histograma del parentesco lateral de los pasajeros clasificado por género y clase de huésped. Además de la regresión lineal aplicada a las gráficas de dispersión. Fuentes: elaboración propia.*

Conclusiones respecto a la variable 'Edad'

- **Histograma de Edad:** Muestra la distribución de edades por género y clase con un ligero sesgo a la derecha (0.39). La Clase 1 agrupa a los pasajeros de mayor edad y más dispersos; la Clase 2 destaca por jóvenes y niños; y la Clase 3 concentra la mayor cantidad de hombres jóvenes y familias.
- **Edad vs. Hermanos / Cónyuges:** Presenta una pendiente negativa en todas las clases: a más hermanos o cónyuges a bordo, menor es la edad promedio. Los bajos valores de R^2 (0.001 a 0.218) indican que la relación lineal es muy débil.
- **Edad vs. Padres / Hijos:** Muestra tendencias divergentes según género y clase debido a que la variable engloba situaciones opuestas (niños con padres o adultos con hijos mayores). Los bajos R^2 (0.023 a 0.135) confirman la falta de una relación lineal clara.
- **Edad vs. Tarifa:** En Clase 1 se observan las tarifas más elevadas sin una relación directa con la edad ($R^2 < 0.04$). En Clases 2 y 3 el costo se concentra en rangos bajos con pendientes descendentes en hombres. En general, la tarifa no predice la edad de forma lineal ($R^2 < 0.12$).

Conclusiones respecto a la variable 'Tarifa'

- **Histograma de Tarifa:** Muestra una fuerte asimetría positiva (4.79), donde la gran mayoría de los pasajeros pagaron tarifas muy bajas. La Clase 3 concentra la mayor acumulación de billetes de menor costo, mientras que la Clase 1 presenta la mayor dispersión y las tarifas más elevadas (hasta >500).
- **Tarifa vs. Edad:** Presenta rectas con pendientes casi planas o levemente descendentes y valores de R^2 muy bajos (0.000 a 0.111). Esto confirma que la edad no influía de forma lineal en el precio del billete dentro de ninguna clase.
- **Tarifa vs. Padres / Hijos:** Muestra pendientes ascendentes en la mayoría de los casos. A mayor número de padres e hijos a bordo, mayor es la tarifa registrada, alcanzando un R^2 de 0.427 en la Clase 3 femenina.
- **Tarifa vs. Hermanos / Cónyuges:** Evidencia una relación lineal positiva notable, especialmente en la Clase 3 ($R^2 = 0.551$ en hombres y 0.654 en mujeres). Esto indica que las tarifas se registraban o compraban acumulativamente en grupo por el tamaño del núcleo familiar a bordo.

Conclusiones respecto a la variable de 'ascendencia y descendencia'

- **Histograma de Padres / Hijos:** Muestra una asimetría positiva (2.75), donde la gran mayoría de los pasajeros viajaban sin padres ni hijos ($Parch = 0$). La Clase 3 concentra la mayor cantidad absoluta de pasajeros sin familiares directos a bordo.
- **Padres / Hijos vs. Edad:** Muestra rectas con pendientes suaves y valores de R^2 bajos (0.026 a 0.135). Esto confirma que la edad no predice de forma lineal la cantidad de padres o hijos, debido a que la variable agrupa tanto a niños con sus padres como a adultos mayores con sus hijos.
- **Padres / Hijos vs. Tarifa:** Presenta pendientes ascendentes constantes en las tres clases, alcanzando un R^2 de 0.427 en la Clase 3 femenina y 0.330 en la masculina. A mayor número de padres o hijos a bordo, mayor es el costo total o tarifa del pasaje.

- **Padres / Hijos vs. Hermanos / Cónyuges:** Evidencia una relación lineal positiva, especialmente en la Clase 3 para hombres ($R^2 = 0.401$). Indica que los grupos familiares integraban múltiples miembros (tanto cónyuges/hermanos como padres/hijos).

Conclusiones respecto a la variable 'Hermanos y conyugues'

- **Histograma de Hermanos / Cónyuges:** Muestra una alta asimetría positiva (3.70), indicando que la gran mayoría de los pasajeros viajaban sin hermanos ni cónyuges ($SibSp = 0$). La Clase 3 concentra la mayor cantidad absoluta de personas solas, predominantemente hombres.
- **Hermanos / Cónyuges vs. Tarifa:** Muestra una fuerte relación lineal positiva en la Clase 3 ($R^2 = 0.551$ en hombres y 0.654 en mujeres), lo que confirma que el costo del billete aumentaba acumulativamente por la compra en grupo familiar. En Clase 1 esta relación lineal es casi nula ($R^2 < 0.06$).
- **Hermanos / Cónyuges vs. Edad:** Presenta pendientes negativas en todas las clases (R^2 hasta 0.218 en Clase 3 masculino). Indica que, a mayor edad, menor es el número de hermanos o cónyuges a bordo, concentrándose los valores altos de hermanos / conyugues en niños y jóvenes.
- **Hermanos / Cónyuges vs. Padres / Hijos:** Evidencia una relación lineal positiva, especialmente marcada en la Clase 3 para hombres ($R^2 = 0.401$). Refleja la existencia de núcleos familiares integrados por múltiples tipos de familiares (tanto cónyuges/hermanos como padres/hijos).

Regresión Logística

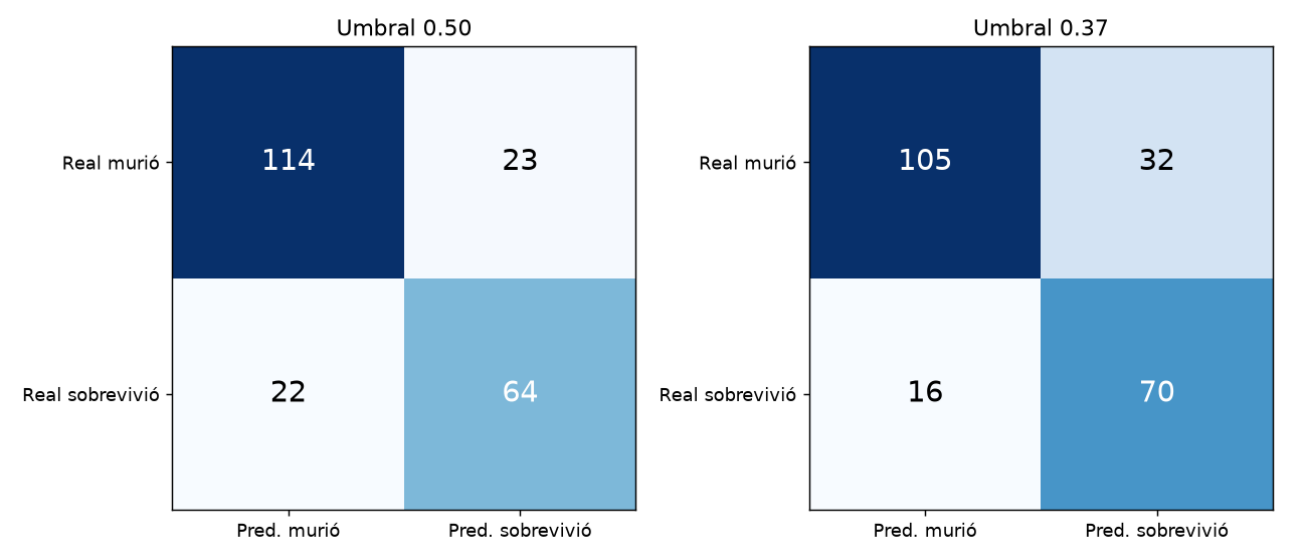


Ilustración 5. *Comparativa de dos matrices de confusión con un umbral distinto. Fuentes: elaboración propia.*

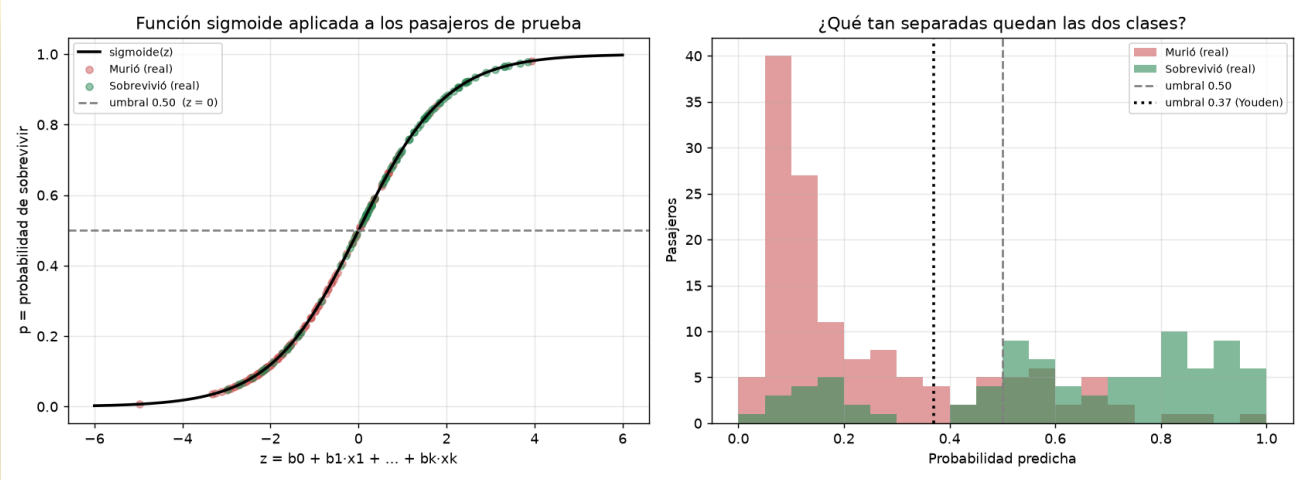


Ilustración 6. *Función sigmoide a los pasajeros de pruea. Y comparación entre humbrales. Fuentes: elaboración propia.*

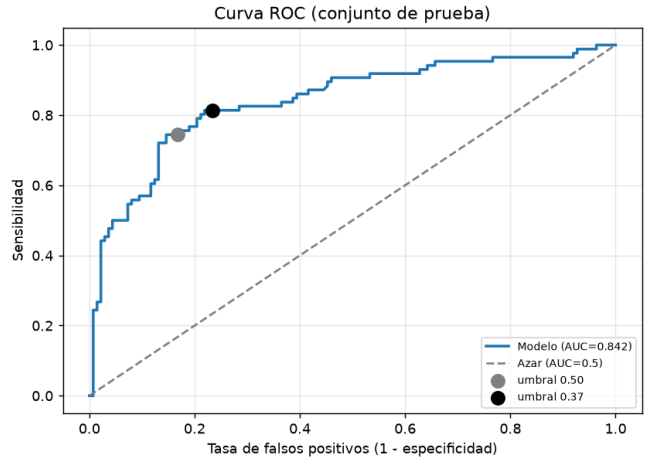


Ilustración 7. Curva ROC y AUC

Función Sigmoide aplicada a los pasajeros: Ilustra cómo el modelo transforma la combinación lineal de variables en una probabilidad acotada entre 0 y 1. Se observa una clara tendencia donde los pasajeros que fallecieron se concentran en valores de $z < 0$ ($p < 0.50$), mientras que los sobrevivientes se agrupan predominantemente en $z > 0$ ($p > 0.50$), con una zona de solapamiento cerca del punto de inflexión ($z = 0$).

Distribución de Probabilidades Predichas: Muestra la capacidad de separación real del modelo entre ambas clases. La mayoría de las personas que fallecieron presentan probabilidades predichas muy bajas (0.0 a 0.3), mientras que los sobrevivientes se concentran hacia el extremo superior (0.5 a 1.0). El umbral predeterminado de 0.50 deja a varios sobrevivientes reales en la zona no clasificada, lo que justifica ajustar el umbral a 0.37 para capturar a estos pasajeros sin distorsionar demasiado la predicción de fallecidos.

Métricas según el Umbral: Muestra el compromiso entre las distintas métricas de evaluación al modificar el punto de corte:

- En el umbral 0.50, la *Exactitud* y la *Especificidad* alcanzan valores elevados (~80% y ~85%), pero la *Sensibilidad* decae (~70%).
- En el umbral óptimo 0.37 (Youden), la *Sensibilidad* y la *Especificidad* se equilibran cerca del $78\% - 80\%$, maximizando la métrica $F1$ y reduciendo las omisiones de sobrevivientes sin perder precisión global significativa.

Curva ROC: Con un área bajo la curva de AUC $= 0.842$, se demuestra que el modelo posee una alta capacidad discriminativa para clasificar correctamente entre quienes sobrevivieron y quienes no. El desplazamiento del punto del umbral 0.50 al 0.37 sobre la curva evidencia cómo se incrementa la Tasa de Verdaderos Positivos con un incremento controlado en la Tasa de Falsos Positivos.

Conclusión

Bajos R^2 generales (< 0.22, la mayoría < 0.05): La edad no predice linealmente el costo del billete ni la cantidad de familiares a bordo. Excepción en Clase 3 (R^2 de hasta 0.654): La tarifa aumenta linealmente a mayor número de Hermanos / Conyugues y Padres / Hijos debido al cobro agrupado del núcleo familiar. Tendencias sociodemográficas: Las pendientes negativas en Edad vs. Hermanos / Conyugues confirman que los pasajeros con más hermanos eran en su mayoría niños y jóvenes. Justificación metodológica: La falta de alineación lineal en las variables evidencia que la regresión lineal no es adecuada para clasificar, justificando el uso de la regresión logística.

Y el modelo de regresión logística ajustado para el Titanic es sólido y discriminativo. El análisis combinado de estas gráficas demuestra que utilizar el umbral por defecto subestima la probabilidad de supervivencia de un grupo de pasajeros; por ello, reducir el umbral constituye la decisión de diseño óptima para equilibrar la detección de sobrevivientes y el control de falsos positivos.

Bibliografía

- James, G., Witten, D., Hastie, T., & Tibshirani, R. (2021). An Introduction to Statistical Learning: with Applications in R (2.ª ed.). Springer. https://doi.org/10.1007/978-1-0716-1418-1
- Hosmer, D. W., Lemeshow, S., & Sturdivant, R. X. (2013). Applied Logistic Regression (3.ª ed.). John Wiley & Sons. https://doi.org/10.1002/9781118548387